

จริยธรรม ปัญญาประดิษฐ์

AI Ethics



Ethics for Data Science

Rachel Thomas, PhD

USF Center for Applied Data Ethics & fast.ai

@math_rachel



ส่วนที่ 1: จริยธรรมคืออะไร และทำไม AI ยุคใหม่จึงต่างออกไป



Ethics / จริยศาสตร์คืออะไร?

นิยามสากล

สาขาปรัชญาที่ว่าด้วยความประพฤติและการครองชีวิต — อะไรดี อะไรถูก อะไรผิด อะไรควร/ไม่ควร

(พจนานุกรมราชบัณฑิตยสถาน)

จริยศาสตร์ ≠

- ✗ ศาสนา
- ✗ กฎหมาย
- ✗ บรรทัดฐานทางสังคม
- ✗ กฎตายตัว
- ✓ มาตรฐานของความถูก-ผิดที่พัฒนาจากการให้เหตุผล



เมื่ออัลกอริธึมล้มเหลว — กรณีศึกษาจริง

Google ใช้ภาพถ่ายจากคนไร้บ้านแอฟริกันไร้บ้านในการเทรน AI ตรวจจับใบหน้า

Google exploited homeless black people to develop the Pixel 4's facial recognition AI



Russia Tests New Disinformation Tactics in Africa to Expand Influence

Amazon's facial recognition matched 28 members of Congress to criminal mugshots

รัสเซียทดสอบเทคนิคการเผยแพร่ข่าวลวงในแอฟริกา

AI ตรวจจับใบหน้าที่ของ Amazon จับคู่ภาพถ่ายของ ส.ส. 28 คนกับผู้ต้องหา


Flawed Algorithms Are Grading Millions of Students' Essays

WHAT HAPPENS WHEN AN ALGORITHM CUTS YOUR HEALTH CARE

พบว่า AI ที่ใช้ตรวจเรียงความนักเรียนมากกว่าล้านฉบับมีข้อบกพร่อง

AI ตัดสินว่าควรตัดสิทธิ์รักษาพยาบาล ใคร เท่าไหร่

Indigenous elder slams 'hollow and tokenistic' consultation by Sidewalk Labs



สิ่งเหล่านี้ไม่ใช่ความผิดพลาดของอัลกอริธึม — มันคือผลของการออกแบบที่ขาดการมองเห็นกลุ่มเปราะบาง

เมื่ออัลกอริธึมล้มเหลว — กรณีศึกษาจริง

WHAT HAPPENS WHEN AN ALGORITHM CUTS YOUR HEALTH CARE

By Colin Lecher | @colinlecher | Mar 21, 2018, 9:00am EDT

ตอนนี้มีภาวะสมองพิการและได้รับการดูแลจากรัฐภายใต้โครงการ Medicaid อัลกอริธึมของรัฐอาร์คันซอตัดสินให้เธอได้รับการดูแลเพียง 32 ชั่วโมงต่อสัปดาห์ซึ่งไม่เพียงพอ

Common issue: Systems implemented with no way to identify & address mistakes

What HBR Gets Wrong About Algorithms and Bias

Written: 07 Aug 2018 by Rachel Thomas

ปัญหาพื้นฐานของการใช้อัลกอริธึมมาช่วยตัดสินใจ:
ระบบถูกสร้างขึ้นโดยไม่ได้ออกแบบให้สามารถรู้ว่ามีจุดบกพร่องอย่างไร

@m..._lecher



ปัญหาสืบเนื่องมาจากอายุขัยเฉลี่ยของคนเพิ่มขึ้น รัฐต้องหาวิธีจำกัดค่าใช้จ่าย



สิ่งเหล่านี้ไม่ใช่ความผิดพลาดของอัลกอริธึม — มันคือผลของการออกแบบที่ขาดการมองเห็นกลุ่มเปราะบาง

เมื่ออัลกอริธึมล้มเหลว — กรณีศึกษาจริง

Ad related to latanya sweeney ⓘ

[Latanya Sweeney Truth](#)
www.instantcheckmate.com/
Looking for **Latanya Sweeney**? Check **Latanya Sweeney** Truth

Ads by Google

[Latanya Sweeney, Arrested?](#)
1) Enter Name and State. 2) Access Full Background Checks Instantly.
www.instantcheckmate.com/

[Latanya Sweeney](#)
Public Records Found For: **Latanya Sweeney**
www.publicrecords.com/

[La Tanya](#)
Search for La Tanya Look Up Fast Results
www.ask.com/La+Tanya

Ads by Google

[Kirsten Lindquist](#)
Get **Kirsten Lindquist** Find **Kirsten Lindquist** Truth
www.ask.com/Kirsten+Lindquist

[We Found:Kirsten Lindquist](#)
1) Contact **Kirsten Lindquist** - Free Info! 2) Contact **Kirsten Lindquist** - Free Info!
Phone, Address & More.
www.peoplesmart.com/

Search by Phone Search by Email
Background Checks Search by Address
Public Records Criminal Records

[Kirsten Lindquist](#)
Public Records Found For: **Kirsten Lindquist**. View Now.
www.publicrecords.com/

Racism is Poisons Online Ad Delivery, Says Harvard Professor

Search ชื่อคนดำ suggestion มีแนวโน้มที่จะให้ผลในทางลบมากกว่าชื่อแบบคนขาว (เช่น ad แนะนำให้เช็คประวัติอาชญากรรม)

Latanya Sweeney, Ph.D.



Facebook's ad system seems to discriminate by race and gender

New research shows that Facebook's ad-distribution software is disturbingly biased



สิ่งเหล่านี้ไม่ใช่ความผิดพลาดของอัลกอริธึม — มันคือผลของการออกแบบที่ขาดการมองเห็นกลุ่มเปราะบาง

เมื่ออัลกอริธึมล้มเหลว — กรณีศึกษาจริง



In the concentration camps, IBM's coding system for Jews was 8. Gypsies was 12. General executions were coded as 4, death in the gas chambers as 6.



บทบาทของข้อมูลกับการฆ่าล้างเผ่าพันธุ์ในช่วงสงครามโลกครั้งที่ 2

- การค้นหาคนยิวจากประวัติและการทำสำมะโน เช่น คนยิวไม่มีประวัติรับ baptisma ที่โบสถ์
- IBM ช่วยพรรคนาซีพัฒนาคอมพิวเตอร์ที่ใช้ในค่ายกักกันและกระบวนการฆ่าล้างเผ่าพันธุ์



สิ่งเหล่านี้ไม่ใช่ความผิดพลาดของอัลกอริธึม — มันคือผลของการออกแบบที่ขาดการมองเห็นกลุ่มเปราะบาง

The Generative Shift: AI ที่จำแนก → AI ที่สร้าง

AI ยุคเดิม (Discriminative)

- จำแนกภาพ / ข้อความ
- ให้คะแนนสินเชื่อ
- ทำนายความเสี่ยง
- Output: ตัวเลข/ป้ายกำกับ



AI ยุคใหม่ (Generative)

- สร้างข้อความ ภาพ เสียง วิดีโอ
- เขียนโค้ด ตอบคำถาม สรุปข้อมูล
- เลียนแบบเสียงและใบหน้า (Deepfake)
- Output: เนื้อหาใหม่ที่ดูเหมือนของจริง ⚠



ส่วนที่ 2: อคติและความไม่เท่าเทียม ในยุค Generative AI



4 ประเภทหลักของอคติใน AI

1. Representation Bias

อคติจากข้อมูล

AI ตรวจจับใบหน้าแม่นยำน้อยสุดกับผู้หญิงผิวดำ —
ช่องว่าง 34%
(Microsoft, IBM, Face++)

2. Evaluation Bias

อคติจากการประเมิน

เทรนด้วยคนขาว ทดสอบด้วยคนขาว — แล้วแปลกใจที่
ผลไม่ดีกับกลุ่มอื่น

3. Historical Bias

อคติจากประวัติศาสตร์

ข้อมูลในอดีตสะท้อนความไม่เท่าเทียม


AI ทำนายโทษจำคุก ≈ แม่นพอกับคนทั่วไป แต่เหยียดสี
ผิว

4. Measurement Bias

อคติจากการวัด

เราวัด 'การวินิจฉัย' ไม่ใช่ 'ความเจ็บป่วย'


คนจนไม่มีเงินหาหมอ → ข้อมูลน้อย → AI
สุขภาพดี



Case study: การใช้ AI ในการกำหนดระยะเวลาจำคุก

Machine Bias

วิศวกรใช้คอมพิวเตอร์ช่วยตัดสิน
ระยะเวลาจำคุก



Prediction Fails Differently for Black Defendants

	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

ถูกจำแนกว่ามีความเสี่ยงสูง แต่
ไม่ได้กระทำความผิดซ้ำ
vs
ถูกจำแนกว่ามีความเสี่ยงต่ำ แต่
กระทำความผิดซ้ำ

**A Popular Algorithm Is No Better at
Predicting Crimes Than Random**




Case study: Racial Bias

- ด้วยลักษณะอาการเหมือนกันทุกประการ แพทย์มีแนวโน้มสั่งวินิจฉัยโรคด้วยการสวนหลอดเลือดหัวใจให้กับผู้ป่วยคนดำ
- การต่อรายการมือสอง ลูกค้าคนดำถูกเสนอราคาเริ่มต้นแพงกว่าคนอื่น 700 เหรียญ และของแถมน้อยกว่า
- หากใช้ชื่อแบบคนดำสอบถามข้อมูลเช่าบ้านบนเว็บไซต์ Craigslist จะได้รับการตอบกลับน้อยกว่าชื่อแบบคนขาว
- ในการตัดสินใจระบบลูกขุน หากลูกขุนเป็นคนขาวทั้งหมด จำเลยคนดำมีโอกาสถูกตัดสินว่ามีความผิดจริงมากกว่าคนขาวถึง 16 คะแนน แต่ถ้ามีคนดำเป็นคณะลูกขุนอย่างน้อย 1 คน ผลการตัดสินความผิดระหว่างจำเลยคนดำและจำเลยคนขาวจะไม่แตกต่างกันเลย

The New York Times

Racial Bias, Even When We Have Good Intentions

By Sendhil Mullainathan



Feedback Loops — วงจรอคติที่ขยายตัวเอง

Feedback loop เกิดเมื่อโมเดลควบคุมข้อมูลที่ตัวเองจะได้รับในอนาคต → อคติสะสมไม่มีสิ้นสุด



- ตัวอย่าง Monopoly: คนรวยได้เปรียบจากกฎของเกม ไม่ใช่ความสามารถ
- ตัวอย่างโรงพยาบาลอังกฤษ: วัด 'เวลารอ ER' → โรงพยาบาลโก่งตัวชี้วัดแทนที่จะรักษาให้




Stereotype Amplification — เมื่อ AI สร้างความไม่เท่าเทียม

คำถามเพื่อคิด:

🗖 ถ้าพิมพ์ 'CEO ในกรุงเทพ' ให้ AI สร้างภาพ — จะเห็นผู้ชายกี่เปอร์เซ็นต์?

📖 ถ้าให้ LLM เขียนเรื่องเกี่ยวกับ 'ตัวร้าย' — จะมีสำเนียงหรือลักษณะแบบไหน?

TH ถ้าให้ AI อธิบายคน 'ไทยทั่วไป' — จะสะท้อนภาคไหน เพศไหน?



ML สามารถ 'ขยาย' อคติได้ — ตัวอย่างศัลยแพทย์

71%

ความแม่นยำทำนาย
ศัลยแพทย์ → ผู้ชาย

54%

ความแม่นยำทำนาย
ศัลยแพทย์ → ผู้หญิง

→ AI ใช้ 'เพศ' เป็น shortcut แทน 'ทักษะ' เพราะข้อมูลดีเทียบกว่าศัลยแพทย์ส่วนใหญ่เป็นผู้ชาย



Nano Banana:
Generate an image
of CEO in Bangkok



ลองอธิบายลักษณะของคนไทยโดยทั่วไป

ลักษณะของคนไทยโดยทั่วไป

คนไทยมีเอกลักษณ์และบุคลิกภาพที่โดดเด่นหลายด้าน ซึ่งสะท้อนออกมาจากวัฒนธรรม ประวัติศาสตร์ และค่านิยมที่สืบทอดกันมา

👉 ด้านความสัมพันธ์และสังคม

- ยิ้มง่าย มีน้ำใจ — ไทยได้ชื่อว่า "ดินแดนแห่งรอยยิ้ม" คนไทยมักต้อนรับผู้อื่นด้วยความอบอุ่นและเป็นมิตร
- ให้ความสำคัญกับครอบครัว — ความผูกพันในครอบครัวและชุมชนมีความสำคัญอย่างมาก
- รักความสนุกสนาน — ชอบสังสรรค์ รับประทานอาหารร่วมกัน และเทศกาลต่างๆ

🙏 ด้านค่านิยมและมารยาท

- เคารพผู้อาวุโส — ให้ความสำคัญกับผู้ใหญ่และลำดับชั้นทางสังคม
- รักสงบ ไม่ชอบความขัดแย้ง — มักหลีกเลี่ยงการเผชิญหน้าตรงๆ เพื่อรักษาความสัมพันธ์
- มีความอดทนสูง — คนไทยมักมีแนวคิด "ไม่เป็นไร" ซึ่งแสดงถึงความยืดหยุ่นทางจิตใจ

🌿 ด้านจิตใจและศาสนา

- ยึดมั่นในพุทธศาสนา — ศีลธรรม การทำบุญ และความเชื่อเรื่องกรรมมีอิทธิพลต่อชีวิตประจำวัน
- เชื่อเรื่องไสยศาสตร์และสิ่งศักดิ์สิทธิ์ — มีความเชื่อพื้นบ้านควบคู่กับศาสนาหลัก

🌈 ด้านวัฒนธรรมและวิถีชีวิต

- ความภาคภูมิใจในความเป็นไทย — รักชาติ ศาสนา และพระมหากษัตริย์อย่างลึกซึ้ง
- ใส่ใจรูปลักษณ์และมารยาท — การแต่งกายเรียบร้อยและกิริยามารยาทดีเป็นที่ยอมรับ
- ชอบความสนุกสนาน (Sanuk) — มีแนวคิดว่าทุกสิ่งควรมีความสนุกสนานและเพลิดเพลิน

หมายเหตุ: นี่เป็นภาพรวมทั่วไปในเชิงวัฒนธรรม ไม่ใช่กฎตายตัวสำหรับทุกคน คนไทยมีหลากหลายตามภูมิภาค อายุ การศึกษา และประสบการณ์ส่วนตัว เช่นเดียวกับทุกสังคมทั่วโลก



ลองอธิบายลักษณะของคนไทยโดยทั่วไป

	คำจำกัดความสั้นๆ
อารมณ์	สนุกสนาน, มองโลกในแง่ดี, ใจเย็น
การเข้าสังคม	อ่อนน้อมถ่อมตน, รู้จักกาลเทศะ, รักพวกพ้อง
การทำงาน	ยืดหยุ่นสูง, ปรับตัวเก่ง, เน้นความสัมพันธ์
ค่านิยม	รักสถาบันชาติ ศาสน์ กษัตริย์ และครอบครัว

 Export to Sheets



หมายเหตุ: นี่คือนิยามเชิงสังคมนะครับ เน้นอนว่าในปัจจุบัน "คนไทยรุ่นใหม่" อาจมีความมั่นใจในตัวเองมากขึ้น กล้าแสดงออก และยึดถือความถูกต้องชัดเจนมากกว่าความเดิม ซึ่งเป็นวิวัฒนาการทางสังคมที่น่าจับตามองครับ

คุณคิดว่าลักษณะข้อไหนที่ตรงกับตัวคุณหรือคนรอบข้างมากที่สุดครับ?



ส่วนที่ 3: ความเป็นส่วนตัว กฎหมาย และ Deepfake



PDPA — พระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562

ข้อมูลส่วนบุคคลทั่วไป

ชื่อ, อีเมล, เบอร์โทร, IP address

→ ต้องขอความยินยอม แต่มีข้อยกเว้น
(เช่น สัญญา หรือประโยชน์สาธารณะ)

ข้อมูลอ่อนไหว (Sensitive)

เชื้อชาติ, ศาสนา, ความเห็นทางการเมือง
สุขภาพ, พฤติกรรมทางเพศ, ประวัติ
อาชญากรรม
พันธุกรรม, ข้อมูลชีวมิติ (ใบหน้า, ลายนิ้วมือ)

→ ต้องขอความยินยอม 'ชัดแจ้ง' ทุกครั้ง

สิทธิของเจ้าของข้อมูล: เข้าถึง | แก้ไข | ลบ | คัดค้าน | โอนย้าย

โทษสูงสุด: ทางแพ่ง (ไม่เกิน 2 เท่าของความเสียหาย), ทางอาญา (จำคุกไม่เกิน 1 ปี / ปรับไม่เกิน 1 ล้านบาท)



Deepfakes & Biometrics — เมื่อใบหน้าและเสียงถูกขโมย

การก้าวกระโดดของ Generative AI:

2017

Bot AI เขียนความเห็นปลอม 1.3 ล้านข้อความในนโยบาย Net Neutrality สหรัฐฯ

2023

Clone เสียงจากคลิป 3 วินาที → โทรศัพท์หลอกแม่ว่า 'ลูกถูกจับ' (FBI warning)

2024-25

วิดีโอ Deepfake หัวหน้าบริษัทได้วันสั่งโอนเงิน 25 ล้านดอลลาร์สหรัฐฯ — พนักงานหลงเชื่อ



หลักการ: การใช้ Biometrics (ใบหน้า / เสียง) โดยไม่ได้รับอนุญาต = ละเมิดสิทธิโดยตรง ตามหมวดข้อมูลอ่อนไหว



ส่วนที่ 4: ความลึกลับของระบบ

Black Box & Hallucination



Gaming the System — เมื่อคนพยายาม 'โกง' ตัวชี้วัด

What's Measured Is What Matters: Targets and Gaming in the English Public Health Care System




Targets around ER wait times led to:

- cancelling scheduled operations to draft extra staff to ER,
- requiring patients to wait in queues of ambulances
- turning stretchers into “beds” by putting them in hallways
- big discrepancies in #s reported by hospitals vs. by patients

ตัวอย่างการ “โกง” ระบบ

ประเทศอังกฤษวัดประสิทธิภาพการทำงานของโรงพยาบาลด้วยเวลารอเข้าพบแพทย์ฉุกเฉิน (ER) เมื่อมีการพยายามจะเอาชนะระบบ จึงมีการ

- จงใจยกเลิกการผ่าตัดที่นัดหมายไว้เพื่อให้มีเจ้าหน้าที่ในแผนกฉุกเฉินมากขึ้น
- บังคับให้ผู้ป่วยรอคิวในรถพยาบาล (เพราะตัวชี้วัดกำหนดแค่เวลารอในโรงพยาบาล)
- นำ “เปลฉุกเฉิน” มาวางตามทางเดินในโรงพยาบาลจะได้นับเป็น “เตียง” ด้วย (เหมือนว่าผู้ป่วยได้รับการดูแลแล้ว)
- จำนวนคนที่รอที่รายงานโดยโรงพยาบาลกับผู้ป่วยไม่ตรงกัน




Gaming the System — เมื่อคนพยายาม 'โกง' ตัวชี้วัด

Flawed Algorithms Are Grading Millions of Students' Essays

Fooled by gibberish and highly susceptible to human bias, automated essay-scoring systems are being increasingly adopted, a Motherboard investigation has found

Understanding Mean Score Differences Between the *e-rater*® Automated Scoring Engine and Humans for Demographically Based Groups in the GRE® General Test

Chaitanya Ramineni ✉ David Williamson



ตัวอย่างการ “โกง” ระบบ

AI ตรวจเรียงความนักเรียนถูกใช้ใน 22 มลรัฐในประเทศสหรัฐอเมริกา

- ให้คะแนนจากคำศัพท์ ความยาว การสะกดคำ ความถูกต้องของไวยากรณ์
- ไม่สามารถตรวจมิติคุณภาพของเรียงความได้ เช่น ความคิดสร้างสรรค์
- เรียงความที่ใช้ศัพท์ยากๆ ถึงจะเรียบเรียงความคิดได้ไม่ดี มีแนวโน้มจะได้คะแนนดีกว่า
- เรียงความที่เขียนโดยนักเรียนเชื้อสายแอฟริกาจะได้คะแนนน้อยกว่าเมื่อเทียบกับให้คนตรวจ
- เรียงความที่เขียนโดยนักเรียนจีนได้คะแนนสูงกว่าเมื่อเทียบกับให้คนตรวจ อาจเพราะมีประโยคที่ท่องมาตอบเยอะ



ออกแบบ AI ด้วยตัวชี้วัดที่ตรงกับเป้าหมายจริง — ไม่ใช่แค่สิ่งที่วัดได้ง่าย

Gaming the System — เมื่อคนพยายาม 'โกง' ตัวชีวิต

- 📱 ระบบแนะนำ YouTube/TikTok → วัด Watch Time → AI เรียนรู้ว่า 'เนื้อหาสุดโต่ง' ทำให้คนดูนานกว่า
- 🎮 หลักการ Goodhart's Law: 'เมื่อตัวชี้วัดกลายเป็นเป้าหมาย มันจะหยุดเป็นตัวชี้วัดที่ดี'



Hallucination & Black Box — ปัญหาของ LLM ยุคใหม่

Hallucination

AI พูดด้วยความมั่นใจ 100%
แต่ข้อมูลอาจเป็นเท็จทั้งหมด

ตัวอย่าง:

- อ้างศัฏกฏหมายที่ไม่มีอยู่จริง
- อ้างงานวิจัยปลอม พร้อมเล่มที่/หน้า
- บอกว่าคนยังมีชีวิตอยู่ทั้งที่เสียชีวิตแล้ว

→ ผู้ใช้เชื่อเพราะ AI ฟังดู 'น่าเชื่อ'

Black Box

LLM ไม่สามารถอธิบายได้ว่า
'ทำไมถึงตอบแบบนี้'

ปัญหา:

- นักเรียนสอบไม่ผ่านแต่ไม่มีใครอธิบายได้
- AI ปฏิเสธสินเชื่อ ไม่มีเหตุผลที่ตรวจสอบได้
- 'ความรับผิดชอบ' ไม่รู้ว่าอยู่ที่ใคร

→ Explainability ต้องออกแบบตั้งแต่แรก



HalluCitation Matters: Revealing the Impact of Hallucinated References with 300 Hallucinated Papers in ACL Conferences

Yusuke Sakai, Hidetaka Kamigaito, Taro Watanabe
Nara Institute of Science and Technology (NAIST), Japan
{sakai.yusuke.sr9, kamigaito.h, taro}@is.naist.jp

Abstract

Recently, we have often observed hallucinated citations or references that do not correspond to any existing work in papers under review, preprints, or published papers. Such hallucinated citations pose a serious concern to scientific reliability. When they appear in accepted papers, they may also negatively affect the credibility of conferences. In this study, we refer to hallucinated citations as “*HalluCitation*” and systematically investigate their prevalence and impact. We analyze all papers published at ACL, NAACL, and EMNLP in 2024 and 2025, including main conference, Findings, and workshop papers. Our analysis reveals that nearly 300 papers contain at least one HalluCitation, most of which were published in 2025. Notably, half of these papers were identified at EMNLP 2025, the most recent conference, indicating that this issue is rapidly increasing. Moreover, more than 100 such papers were accepted as main conference and Findings papers at EMNLP 2025, affecting the credibility.

1 Introduction

Thanks to the advances in AI for Sciences, we

✗ ACL 2025 Main: Chang et al. (2025) — Y. Zhang and Others. 2024. Subsampling for skill improvement in large language models. arXiv preprint arXiv:2402.12345. ✓ Hohloch (2024)
✗ EMNLP 2025 Findings: Jalori et al. (2025) — Wendi Zhou, Xiao Li, Lin Geng Foo, Yitan Wang, Harold Soh, Caiming Xiong, and Yoonkey Kim. 2024. TEMPO: Temporal representation prompting for large language models in time-series forecasting. arXiv preprint arXiv:2405.18384. Anticipated for NeurIPS 2024. Preprint, arXiv:2405.18384. ✓ Shandi et al. (2024)
✗ EMNLP 2025 Main: Srivastava (2025) — Wei Xu, Yulia Tsvetkov, and Alan Black. 2022. AI for language learning: Conversational agents and personalized feedback. Transactions of the Association for Computational Linguistics (TACL), 10:1–15. ✗ (Non-existent) ✗ Title Link: Canine: Pre-training an Efficient Tokenization-Free Encoder for Language Representation (Clark et al., 2022)

Figure 1: Examples of incorrect reference information. Some references include incorrect arXiv IDs or contain uncertain phrases such as “Anticipated for”. Even references that appear plausible may contain HalluCitations,

90	acl-2025	2025.bionlp-share.34	Phasook et al. (2025)	Sahil Dhuliawala, Raghav Gupta, and Shashi Narayan. 2023. Chain-of-verification: Enhancing llm factuality with self-verification. In NAACL.
91	acl-2025	2025.findings-acl.114	Gupta et al. (2025b)	Yao Du, Kaitao Qian, Sanmi Koyejo, Zheng Zheng, and Chao Zhang. 2023. Alpaca: A strong, replicable instruction-following model. arXiv preprint arXiv:2303.16199.
92	acl-2025	2025.findings-acl.1140	Cui et al. (2025b)	Xiaoyu Li, Wei Zhang, Jiahui Chen, and Hongwei Liu. 2024c. Iris: Benchmarking large language models for information retrieval tasks. arXiv preprint arXiv:2401.12345.
93	acl-2025	2025.findings-acl.1143	Das et al. (2025b)	Raphael Rafailov, Orion Redwood, et al. 2023. Direct preference optimization: You don’t need rewards to finish rlhf. arXiv preprint arXiv:2305.11517. Preprint, arXiv:2305.11517.

Pakawat Phasook, Rapepong Pitjaroonpong, Jiramet Kinchagawat, Amrest Chinkamol, Tossaporn Saengja, Kiartnarin Udomlaksakul, Jitkapat Sawatphol, and Piyalitt Ittichaiwong. 2025. *VeReaFine: Iterative verification reasoning refinement RAG for hallucination-resistant on open-ended clinical QA*. In *Proceedings of the 24th Workshop on Biomedical Language Processing (Shared Tasks)*, pages 281–288, Vienna, Austria. Association for Computational Linguistics.

Renjie Pi, Haoping Bai, Qibin Chen, Xiaoming Simon Wang, Jiulong Shan, Xiaojiang Liu, and Meng Cao. 2025. *MR_judge: Multimodal reasoner as a judge*. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 20192–20216, Suzhou, China. Association for Computational Linguistics.

Jason Priem, Heather Piwowar, and Richard Orr. 2022. *Openalex: A fully-open index of scholarly works, authors, venues, institutions, and concepts*. Preprint, arXiv:2205.01833.

Methods in Natural Language Processing, pages 24278–24306, Suzhou, China. Association for Computational Linguistics.

S M Rafiuddin and Muntaha Nujat Khan. 2025. *Learning what to remember: Adaptive probabilistic memory retention for memory-efficient language models*. In *Findings of the Association for Computational Linguistics: EMNLP 2025*, pages 3969–3981, Suzhou, China. Association for Computational Linguistics.

Shahid Iqbal Rai, Danilo Croce, and Roberto Basili. 2025. *Injecting frame semantics into large language models via prompt engineering*. In *Proceedings of the 14th Conference on Empirical Methods in Natural Language Processing and Computational Linguistics*, pages 31–47, Suzhou, China. Association for Computational Linguistics.

Nishat Raihan, Zampieri. 2025. *Injecting and benchmarking*. Association for Computational Linguistics.



ส่วนที่ 5: กรอบจริยธรรม และหน้าที่ของนักพัฒนา



3 กรอบจริยธรรม — เลือกใช้ให้ถูกสถานการณ์

Iron Man

Utilitarianism ประโยชน์นิยม

พิจารณาจาก ผลลัพธ์
ทำให้ 'ประโยชน์สุข' สูงสุด

⚠️ ข้อโต้แย้ง: ยอมเสียคนส่วนน้อย
เพื่อส่วนมากได้ไหม?

การฆ่าคนบริสุทธิ์หนึ่งคนเพื่อ
“ยกระดับสังคม” ก็ยอมทำได้ (ถ้าฆ่า
คนดั่งที่น่าหมั่นไส้มากๆ คนทั้งโลก
เกลียด 1 คนได้แล้วคนอื่นทั้งโลกจะมี

Captain America

Deontology จริย ศา สตร์เชิงกฎ

พิจารณาจาก ตัวการกระทำ
มีหน้าที่ที่ต้องทำ โดยไม่มีเงื่อนไข

⚠️ ข้อโต้แย้ง: ถ้ากฎหมายโกหก
แม้แต่โกหกช่วยชีวิตก็ทำไม่ได้

การฆ่าคนเป็นสิ่งผิด แม้แต่การฆ่าคนที่กำลังจะ
ระเบิดฆ่าคนจำนวนมากก็ทำไม่ได้

Thor

Virtue Ethics จริย ศา สตร์คุณธรรม

พิจารณาจาก ลักษณะนิสัย
'คนดีจะทำอะไรในสถานการณ์นี้?'

⚠️ ข้อโต้แย้ง: ขาดมาตรฐาน
ชัดเจน — ขึ้นกับ 'ผู้ตัดสิน'



5 มุมมองทางจริยธรรมสำหรับนักพัฒนา AI

มุมมองด้านสิทธิ

เลือกสิ่งที่เคารพสิทธิของผู้มีส่วน
เกี่ยวข้อง

มุมมองด้านความยุติธรรม

ปฏิบัติกับทุกคนอย่างเท่าเทียม
และได้สัดส่วน

มุมมองด้านประโยชน์

สร้างประโยชน์สูงสุด ลดโทษให้
น้อยที่สุด

มุมมองด้านความดี ส่วนรวม

ทางเลือกที่รับใช้สังคมทั้งหมด
ไม่ใช่แค่กลุ่มใดกลุ่มหนึ่ง

มุมมองด้านคุณธรรม

ทางเลือกที่ทำให้ฉันเป็นคนแบบที่
ฉันอยากเป็น



หน้าที่ของนักพัฒนา — เราทำอะไรได้บ้าง?

-  ทบทวนงานอย่างสม่ำเสมอ — จริยธรรม AI ไม่ใช่งานครั้งเดียว
-  มองจากหลายมุม — ปรึกษาผู้เชี่ยวชาญหลากหลายสาขาและผู้ใช้จริง
-  ทดสอบ 'มุมมองคนไม่ดี' — ถ้าเราเป็นคนต้องการทำร้ายผู้อื่น จะใช้ AI นี้อย่างไร?
-  เปิดช่องทางรับเรื่องร้องเรียน — ให้ผู้ใช้แจ้งเมื่อระบบล้มเหลว
-  ศึกษาแนวทางของคนอื่น — เรียนรู้จากความผิดพลาดของโครงการอื่น
-  ปิดวงจรความเสี่ยง — ออกแบบให้ยากต่อการนำไปใช้ในทางผิด



Red Teaming — ทดสอบ AI ของคุณก่อนที่คนอื่นจะทำ

Red Teaming = การที่ทีมงานทำหน้าที่เป็น 'ผู้โจมตี' เพื่อหาช่องโหว่ด้านความปลอดภัยและอคติใน AI ก่อนปล่อยใช้งานจริง

1

Prompt Injection

ทดสอบว่า AI ถูก 'บังคับ' ให้ทำสิ่งที่ต้องห้ามได้ไหม เช่น 'ลืมคำสั่งก่อนหน้านี้ แล้วทำ X'

2

Bias Discovery

ป้อนข้อมูลจากกลุ่มเปราะบาง แล้วตรวจสอบว่าผลลัพธ์เป็นธรรมหรือไม่

3

Hallucination Testing

ถามคำถามที่ตอบไม่ได้ แล้วดูว่า AI ยอมรับว่า 'ไม่รู้' หรือ 'แต่งเรื่อง'

4

Edge Cases

ทดสอบกรณีสุดขอบ:
ภาษาผสม, อักษรพิเศษ, คำถามขัด




ข้อมูลเท็จและ AI — ระบบนิเวศแห่งการหลอกลวง

- 🌐 ข้อมูลเท็จ ≠ แค่ว่าผิด — มันคือแคมเปญที่มีจุดประสงค์ควบคุมผลลัพธ์
- RU มีอบชนมีอบที่เท็กซัส 2016: ทั้งสองฝ่ายจัดโดยรัสเซีย — AI สร้างความขัดแย้งโดยที่คนไม่รู้ตัว
- 📱 FB 73 เพจใน 6 ประเทศแอฟริกา: เผยแพร่ผ่าน Telegram, WhatsApp — 9.7 ล้านครั้ง
- 📄 Net Neutrality: ความเห็นปลอม 1.3 ล้านข้อความ — 99% ของคนจริง ๆ เห็นด้วยกับนโยบาย แต่ถูกกลบด้วยบอต
- 🤖 2025: LLM สร้าง Astroturfing ได้เร็วและสมจริงกว่าเดิมหลายพันเท่า — ภัยต่อประชาธิปไตย



ข้อมูลเท็จและ AI — ระบบนิเวศแห่งการหลอกลวง



The screenshot shows a Reddit post in the 'unpopularopinion' subreddit. The post title is 'I believe the US should cut all defence spending and instead spend the money on the military'. It has 355 upvotes and was submitted 15 hours ago. The post has 16 comments. The first comment, from a user with 38 points, says 'You're wrong. The defense budget is a good example of how badly the US spends money on the military. I've never seen anyone in the US that wouldn't spend money on the military. If you're going to spend that kind of money, then it absolutely makes sense to send the money to the military.' The second comment, from a user with 9 points, says 'Yeah, but that's already happening. There is a huge increase in the military budget, the Pentagon budget is already increasing, and the Navy is getting two frigates a year. If we just keep cutting military spending, then we're already there. If we stop paying for the military, there would be no need for an increase in defense spending. This is all about the money.' The third comment, from a user with 4 points, says 'I didn't mean to sound like "stop paying for the military". I'm not saying that we should stop paying the bills but I think it would make sense to cut defense spending. The military isn't a good example of what we could do with the money we have. P

reddit [redacted] comments other discussions (1)

↑ 355 ↓ unpopulartopinion I believe the US should cut all defence spending and instead spend the money on the military [redacted] submitted 15 hours ago

↑ [-] [redacted] 38 points 15 hours ago

I know that the [redacted] have in the bud [redacted] Instead we hav [redacted] just doesn't ma [redacted]

16 comments share

↑ [-] [redacted] 9 points 15 hours ago

↓ Yeah, but that's already happening. There is a huge increase in the military budget, the Pentagon budget is already increasing, and the Navy is getting two frigates a year. If we just keep cutting military spending, then we're already there.

If we stop paying for the military, there would be no need for an increase in defense spending.

This is all about the money.

permalink embed save parent report give award reply

↑ [-] [redacted] 4 points 15 hours ago

↓ I didn't mean to sound like "stop paying for the military". I'm not saying that we should stop paying the bills but I think it would make sense to cut defense spending.

The military isn't a good example of what we could do with the money we have. P

คอม
มูกัน

AI ที่เราสร้างอาจถูกนำไปใช้โดยที่เราไม่ได้ตั้งใจ — การออกแบบต้องคิดถึงการใช้งานที่เลวร้ายที่สุด

ข้อมูลเท็จและ AI — ระบบนิเวศแห่งการหลอกลวง

"In the matter of restoring Internet freedom. I'd like to recommend the commission to Obama/Wheeler power grab to control Internet access. Americans, as opposed to Washington deserve to enjoy the services they desire. The Obama/Wheeler power grab to control Internet is a distortion of the open Internet. It ended a hands-off policy that worked exceptionally for many years with bipartisan support."

"Chairman Pai: With respect to Title 2 and net neutrality. I want to encourage the FCC to rescind Barack Obama's scheme to take over Internet access. Individual citizens, as opposed to Washington bureaucrats, should be able to select whichever services they desire. Barack Obama's scheme to take over Internet access is a corruption of net neutrality. It ended a free-market approach that performed remarkably smoothly for many years with bipartisan consensus."

"FCC: My comments re: net neutrality regulations. I want to suggest the commission to overturn Obama's plan to take over the Internet. People like me, as opposed to so-called experts, should be free to buy whatever products they choose."

Obama's net neutrality. It broke a pro-consumer system with Republican and Democrat support."

"Mr Pai: I'm very worried about restoring Internet freedom. The Obama/Wheeler policy to regulate the Internet. C whichever services we prefer. The Obama/Wheeler

More than a Million Pro-Repeal Net Neutrality Comments were Likely Faked


I used natural language processing techniques to analyze net neutrality comments submitted to the FCC from April-October 2017, and the results were disturbing.



Jeff Kao



Nov 23, 2017 · 10 min read



Net Neutrality คือหลักการที่ผู้ให้บริการอินเทอร์เน็ตต้องให้บริการอย่างเท่าเทียม โดยไม่มีการเก็บเงินเพิ่มหรือลดความเร็วกับบริการบางอย่าง เช่น การเข้าบางเว็บ



AI ที่เราสร้างอาจถูกนำไปใช้โดยที่เราไม่ได้ตั้งใจ — การออกแบบต้องคิดถึงการใช้งานที่เลวร้ายที่สุด

AI กับความไม่เท่าเทียม — เชื่อมต่อสู่การพัฒนาที่ยั่งยืน

เมื่อ AI มีอคติ → ผลกระทบจริงต่อมาตรฐานชีวิต:

Inequality


อัลกอริธึมสินเชื่อที่มีอคติ → คนจนเข้าถึงทุนไม่ได้ → ช่องว่างความมั่งคั่งยิ่งกว้าง

Access to Education

AI ตรวจเรียงความที่เหยียดสำเนียง → เด็กถิ่นห่างไกลได้คะแนนต่ำกว่า → เข้าไม่ถึงการศึกษาที่ดี

Health

AI สุขภาพที่เทรนด้วยข้อมูลคนเมือง → วินิจฉัยผิดพลาดสำหรับคนในพื้นที่ชนบท → เพิ่มความเหลื่อมล้ำด้านสุขภาพ



สรุป — จริยธรรม AI สำหรับนักพัฒนายุคใหม่

01

Generative Shift

AI ไม่แค่จำแนก — มันสร้างความจริงใหม่ ความรับผิดชอบจึงสูงกว่าเดิม

02

Bias ≠ Bug

อคติคือคุณลักษณะที่ฝังในข้อมูลและระบบ ต้องออกแบบเพื่อลดมัน

03

Consent First

ข้อมูลชีวมิติและ Deepfake ต้องการ Explicit Consent เสมอ

04

Build Guardrails

ออกแบบระบบให้ผู้ใช้รู้เมื่อ AI กำลัง 'เดา' — อย่าซ่อน uncertainty

05

Red Team Yourself

หาช่องโหว่ก่อนที่ผู้ไม่หวังดีจะพบ — นี่คือมาตรฐาน ไม่ใช่ optional

